12 de setembro de 2020

Usando *R* para entender a COVID-19

Proposta da palestra

- Visão geral da apresentação: foco em R, pandemia como motivação;
- Perfil do apresentador;
- Perfil esperado do público.

O que é o R ?

- Biblioteca completa de estatística – com acesso à Internet: Twitter;
- Software livre casa bem com academia;
- Ambiente expansível com bibliotecas de alto desempenho em C/C++;
- Linguagem interpretada de alto nível, especializada em estatística;
- Mundo à parte da estatística.

Características de uma pandemia

- Processo exponencial;
- 1 pessoa contagia 10;
- 10 pessoas contagiam outras 10 cada uma;
- No passo 0, $10^0 = 1$ pessoa;
- No passo 1, $10^1 = 10$ pessoas;
- No passo 2, $10^2 = 100$ pessoas etc.

Obtendo dados através do R

scripts/get–full_data.R

```
url <- "https://github.com/owid/covid-19-data/raw/master/public/data/owid-covid-data.csv"
full_data <- read.csv(url, header=TRUE)
```

- uso de *snippets* para reduzir erros de digitação;
- endereçamento dos dados através de URL;
- normalmente (mesmo em Python) os dados seriam baixados em arquivo, depois processados.

Filtragem dos dados da pandemia

scripts/gen–work.R

```
brazil <- subset(full_data, iso_code == 'BRA')
work <- subset(brazil, total_cases > 0)
```

- Mas os dados do pacote de dados `brazil` ainda não estão como necessário;
- O registro da pandemia no mundo começou no último dia de 2019;
- Mas no Brasil, ele começou apenas em fevereiro, início do primeiro caso.
- Filtra-se então o pacote `brazil` para se ter o pacote de trabalho `work`;
- Usa-se a variável `total_cases` porque `new_cases` foi nula em alguns dias do início da pandemia.

Apresentação dos dados da pandemia (`show_work.R`)

scripts/show–work.R

```
View(work)
ncol(work)
nrow(work)
str(work)
```

- A função `View(work)` apresenta os dados em uma planilha;
- A função `ncol(work)` informa quantas colunas há nesses dados;
- A função `nrow(work)` informa quantas linhas há nesses dados;
- A função `str(work)` informa a estrutura desses dados, além de permitir uma "xereteda" neles;

Escolha de dados: `new_cases` e `total_cases`

- Usaremos os casos de infecção, não de falecimentos, ou *deaths*;
- As duas variáveis são relacionadas, mas os casos são em maior quantidade e, portanto, menos sujeitos a erros de medida.
- Contudo, resta decidir se devemos usar a ocorrência diária de novos casos (`new_cases`) ou seu valor acumulado `total_cases`.
- Uma forma simples de avaliar variáveis é através de sua apresentação em gráfico – sua "plotagem", ou *plot*.

Criação de variável de apoio day

scripts/creat–day.R

```
day <- 1:length(work$total_cases)
day
```

- Infelizmente, como vimos nas apresentações dos dados, as variáveis de fator são preservadas nos subpacotes de dados;
- Assim, a variável `date` será sempre iniciada a partir de 2019-12-31, não do início da pandemia.
- Por isso criamos a variável `day` que terá valor 1 no primeiro dia da pandemia, e terá tantos elementos quanto os dias em que a pandemia foi registrada.
- No *script* `length(work$total_cases)` define o comprimento total (ou número de linhas) da variável `total_cases` do pacote de dados `work` que estamos trabalhando;
- o cifrão `$` informa a subordinação entre `work` e `total_cases`; ou seja: `total_cases` *pertence* ao pacote `work`.

Plotagem de `day` versus `new_cases`

scripts/plot–new_cases.R

```
plot(day, work$new_cases)
```

- O programa é fácil de ser entendido ele desenha (*to plot*) duas variáveis: uma na abscissa (ou x) e outra na ordenada (ou y) – respectivamente `day` e `work$new_cases`.
- Mas o desenho resultante é difícil de ser entendido: a partir dos primeiros 70 dias não há mais um padrão claro.

Plotagem de day versus new_cases (*cont*)

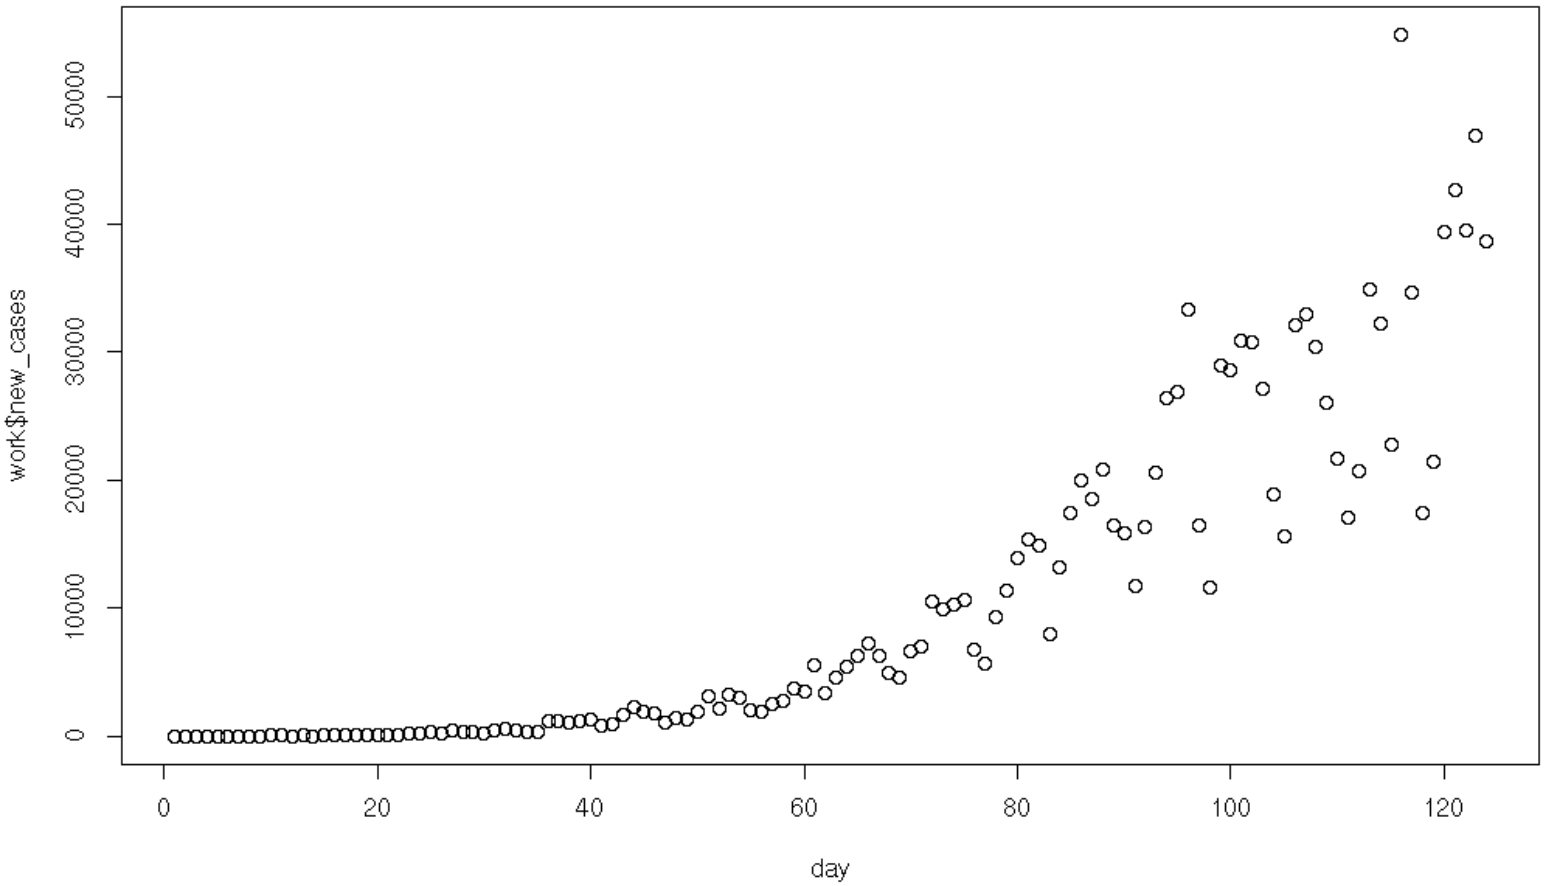

Plotagem de day versus total_cases

scripts/plot–total_cases.R

```
plot(day, work$total_cases)
```

- A compreensão do programa é a mesma do caso anterior; naturalmente substituindo `new_cases` por `total_cases`.
- Mas é muito mais fácil ver um padrão na variável `total_cases` do que na variável `new_cases`.
- Por isso é com ela que seguiremos os estudos.

Plotagem de day versus `total_cases` (*cont*)

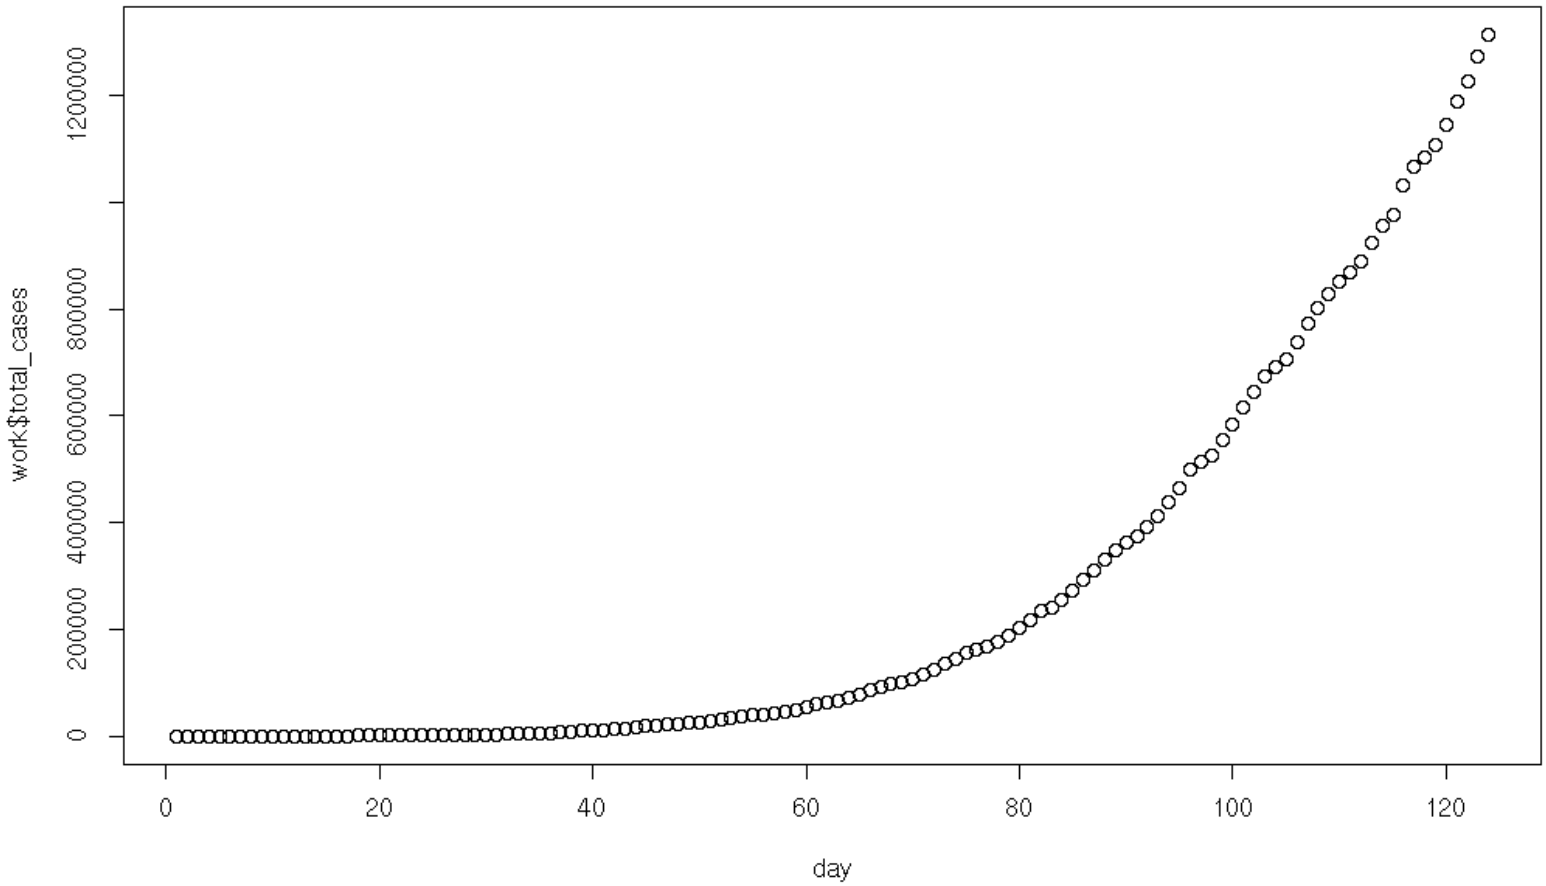

O que é uma função exponencial

- A função exponencial clássica é $y = e^x$, onde e é a chamada *constante de Euler*.
- Ela é muito importante para a matemática, mas neste caso estamos interessados em sua propriedade de crescer muito rapidamente.
- Essa equação simples será reescrita como $T = e^{\alpha d + \beta}$.
- Seguindo o hábito dos matemáticos, de usar uma única letra para variáveis, T significa `total_cases` e d signfica `day`.
- α e β são constantes que dão mais flexibilidade ao ajuste da função.

Uso de logaritmo para facilitar a regressão linear

- Infelizmente, a técnica de regressão linear trabalha apenas com retas, planos e similares.
- Para fazer surgir uma reta neste caso, aplica-se a função logaritmo nos dois lados da igualdade:

$$log(T) = log(e^{\alpha d+\beta}) = \alpha d + \beta.$$

- a transformação de $log(e^{\alpha d+\beta})$ em $\alpha d + \beta$ é possível porque $log(x)$ e e^x são funções inversas.
- Sua *composição* (aplicação sucessiva) é a *função identidade*.
- Ou seja: $log(e^x) = x$. Além disso, $e^{log(x)} = x$

Regressão de day versus *log*(*total_cases*)

scripts/plot–exp.R

```
total_cases_log <- log(work$total_cases)
df_exp <- data.frame(day, total_cases_log)
fm_exp <- lm(total_cases_log ~ day, data = df_exp)

dev.off()
plot(df_exp$day, df_exp$total_cases_log)
lines(df_exp$day, fm_exp$fitted.values)
```

- Primeiro criamos a variável `total_cases_log` transformando os valores de `total_cases` através da função *log*();
- Depois criamos o *data frame* `df_exp` para a regressão.
- A seguir, plotamos as variáveis usadas e a reta aproximada.

Regressão de day versus *log*(*total_cases*) (*cont.*)

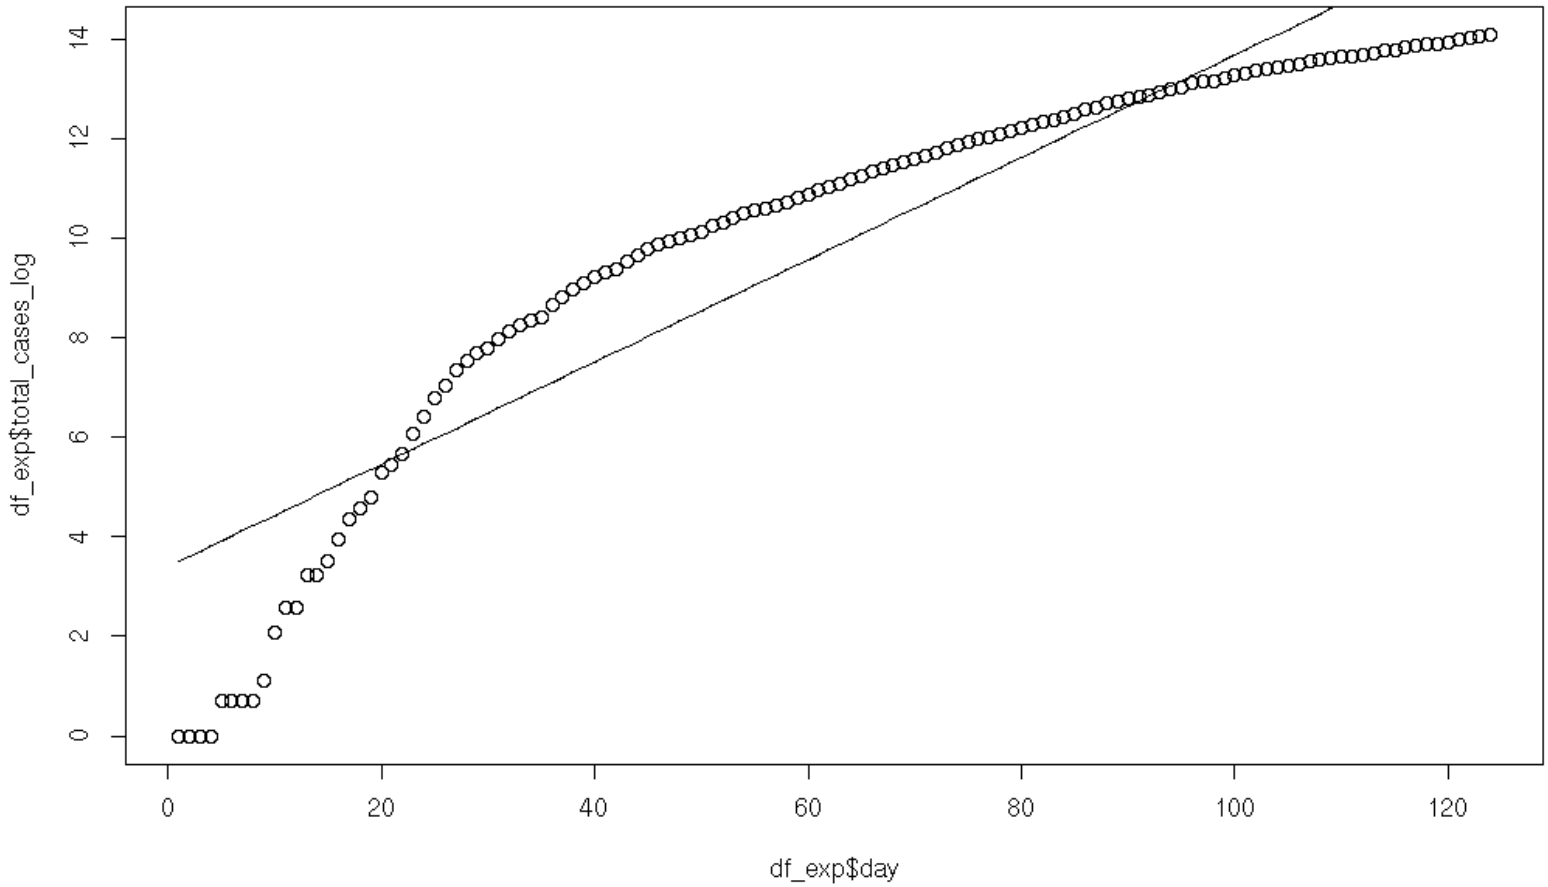

Melhor aproximação $T = e^{\gamma d^2 + \delta d + \epsilon}$

- Para melhorar o ajuste de uma função de `day` à variável dependente `total_cases`, incluiremos um termo quadrático.
- Ou seja: tentaremos expressar `total_cases` através de uma parábola de `day`, em vez de simples reta.
- Uma parábola tem a vantagem de que seu crescimento é variável e podemos ajustá-la a trechos dos dados.

Adição de day^2 à função exponencial

scripts/plot–exp2.R

```
day_sq <- day * day
df_exp2 <- data.frame(day, day_sq, total_cases_log)
fm_exp2 <- lm(total_cases_log ~ day + day_sq, data = df_exp2)

dev.off()
plot(df_exp2$day, df_exp2$total_cases_log)
lines(df_exp2$day, fm_exp2$fitted.values)
```

- Primeiro se cria a variável `day_sq` como o quadrado da variável `day`, ou o produto de `day` por ela mesma;
- A seguir, cria-se a *data frame* `df_exp2` para conter todas variáveis da nova regressão;
- O novo modelo de regressão linear agora inclui `day_sq`.
- A seguir, plota-se `day`, `total_cases` e a função aproximada, como feito antes.

Adição de day^2 à função exponencial (*cont.*)

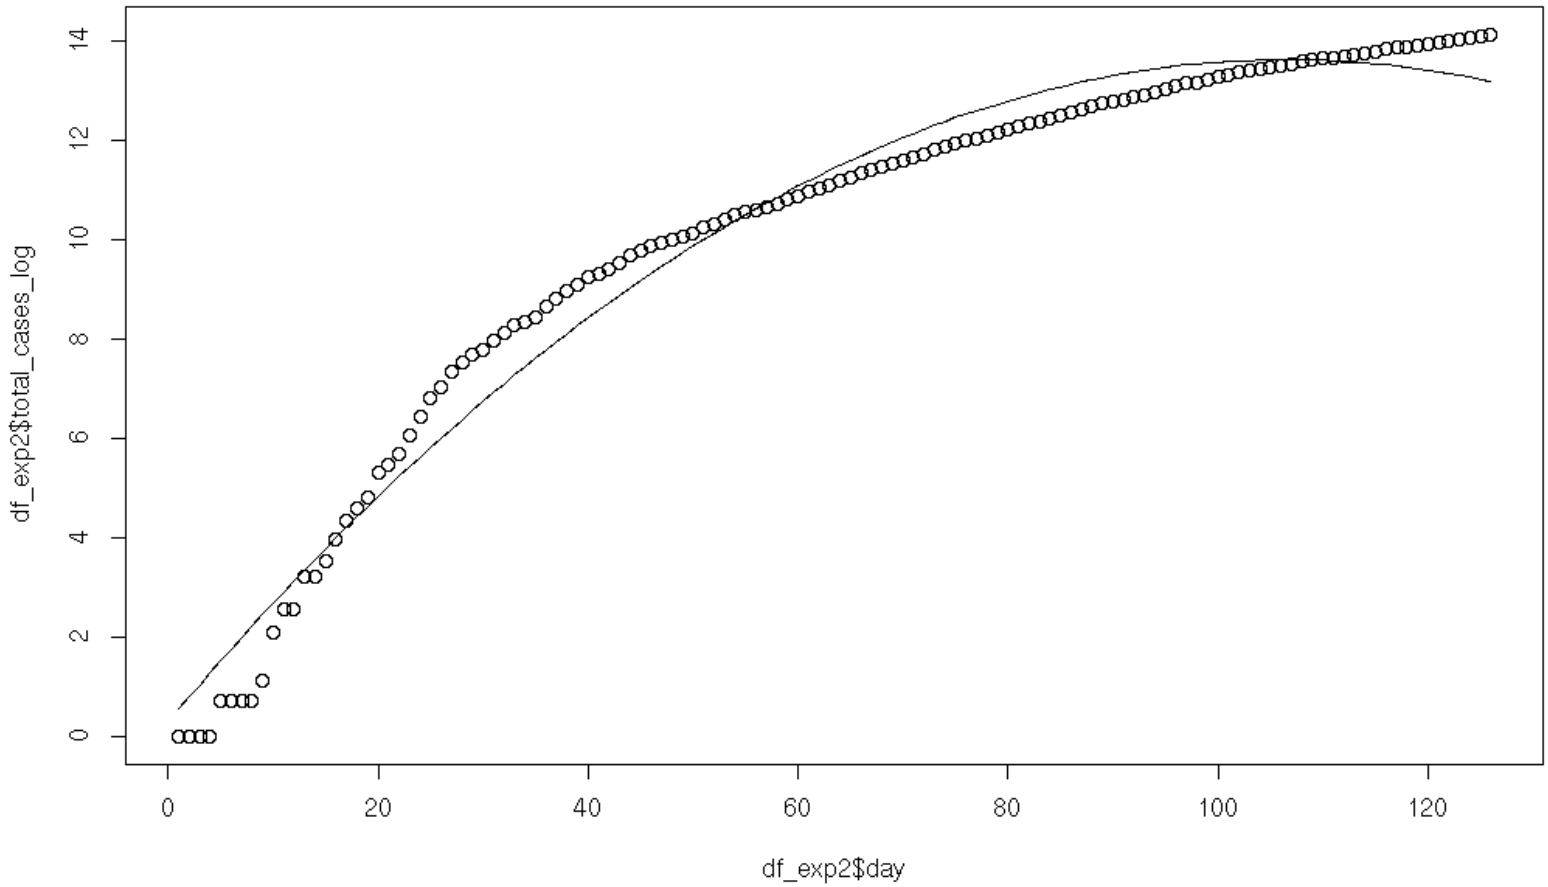

Plotagem da exponencial quadrática sem transformação logarítmica

scripts/plot–unlog2.R

```
fitted_values_exp2 <- exp(fm_exp2$fitted.values)

dev.off()
plot(day, work$total_cases)
lines(day, fitted_values_exp2)
```

- Neste caso, como feito antes, usa-se a função exponencial para converter os dados aproximados em termos de `total_case`, não mais de `log(total_case)`.

Plotagem da exponencial quadrática sem transformação logarítmica (*cont.*)

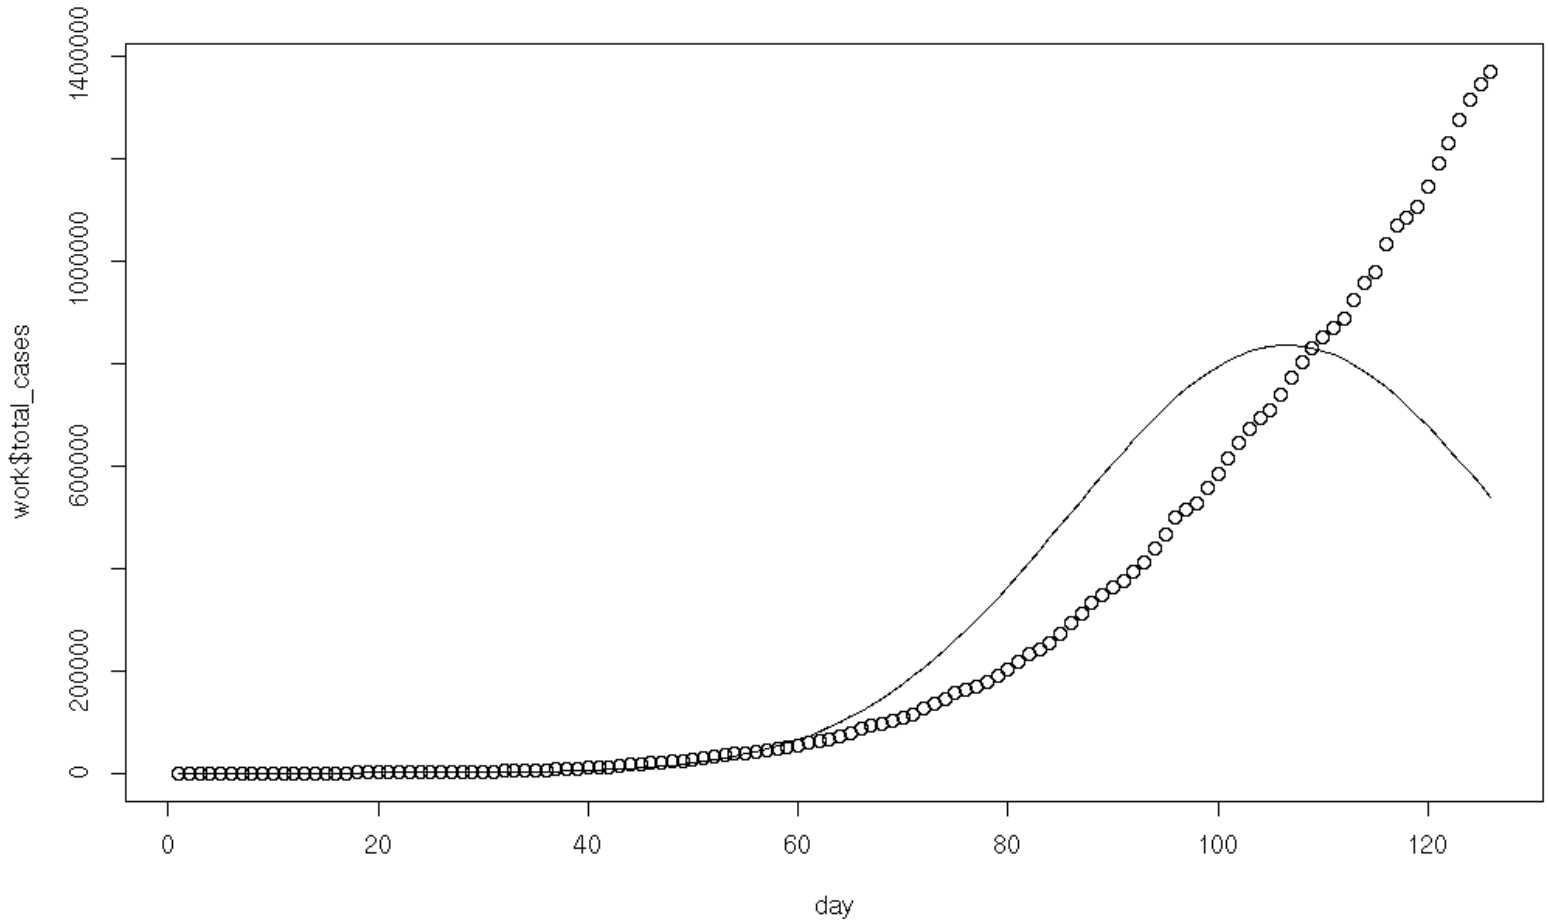

Estimativa do pico da pandemia

scripts/calc–peak.R

```
peak <- -fm_exp2$coefficients["day"] / (2 * fm_exp2$coefficients["day_sq"])
peak

peak <- ceiling(peak)
peak

work$date[peak]
```

- Este *snippet* usa os coeficientes da parábola aproximada para estimar o pico da pandemia.